

Смесь экспертов^{*}

А. В. Грабовой¹, В. В. Стрижов²

Аннотация:

Ключевые слова: ; .

DOI: 00.00000/0000000000000000

1 Введение

2 Постановка задачи

Задана выборка:

$$\mathbf{X} \in \mathbb{R}^{N \times n}, \quad (2.1)$$

где N — количество объектов в выборке, а n — размерность признакового пространства.

2.1 Смесь моделей

Определение 2.1. *Смесь моделей — мультимодель, ответы которой представляют собой взвешенную сумму ответов всех задействованных моделей независимо от объекта.*

$$\hat{\mathbf{f}} = \sum_{k=1}^K \pi_k \mathbf{f}_k, \quad \pi_k = \text{const}, \quad (2.2)$$

где \mathbf{f} — мультимодель, а \mathbf{f}_k является некоторой моделью.

^{*}Работа выполнена при поддержке РФФИ и правительства РФ.

¹Московский физико-технический институт, grabovoy.av@phystech.edu

²Московский физико-технический институт, strijov@ccas.ru

Логистическая регрессия. Рассматривается следующая вероятностная модель:

1. Веса моделей в смеси $\boldsymbol{\pi}$ получены из априорного распределения

$$p(\boldsymbol{\pi}|\boldsymbol{\mu});$$

2. Векторы параметров моделей \mathbf{w}_k получены из нормального распределения

$$p(\mathbf{w}_k|\mathbf{A}_k) = \mathcal{N}(\mathbf{w}_k|\mathbf{0}, \mathbf{A}_k^{-1}), \quad k = 1, \dots, K;$$

3. Для каждого объекта \mathbf{x}_i выбрана модель \mathbf{f}_{k_i} , которой он описывается, причем $p(k_i = k) = \pi_k$;

4. Для каждого объекта \mathbf{x}_i класс y_i определен в соответствии с моделью

$$\mathbf{f}_{k_i} : y_i \sim \text{Be}(\sigma(\mathbf{w}_{k_i}^\top \mathbf{x}_i)),$$

где σ — сигмоидная функция.

Совместное правдоподобие модели:

$$\begin{aligned} p(\mathbf{y}, \mathbf{w}_1, \dots, \mathbf{w}_K, \boldsymbol{\pi}|\mathbf{X}, \mathbf{A}_1, \dots, \mathbf{A}_K, \boldsymbol{\mu}) &= \\ &= p(\boldsymbol{\pi}|\boldsymbol{\mu}) \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k|\mathbf{0}, \mathbf{A}_k^{-1}) \prod_{i=1}^N \left(\sum_{l=1}^K \pi_l \sigma(y_i \mathbf{w}_l^\top \mathbf{x}_i) \right) \end{aligned} \quad (2.3)$$

Введем скрытые переменные $\mathbf{Z} = \{z_{ik}\}$, тогда совместное правдоподобие будет иметь вид:

$$p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z}|\mathbf{X}, \mathbf{A}_1, \dots, \mathbf{A}_K, \boldsymbol{\mu}) = \text{Dir}(\boldsymbol{\pi}|\boldsymbol{\mu}) \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k|\mathbf{0}, \mathbf{A}_k^{-1}) \prod_{i=1}^N \prod_{l=1}^K (\pi_l \sigma(y_i \mathbf{w}_l^\top \mathbf{x}_i))^{z_{il}} \quad (2.4)$$

Используем вариационное приближение (Е-шаг):

$$q(\mathbf{Z}, \mathbf{w}_1, \dots, \mathbf{w}_K, \boldsymbol{\pi}) = q(\mathbf{Z}) q(\mathbf{w}_1, \dots, \mathbf{w}_K) q(\boldsymbol{\pi}) \quad (2.5)$$

Найдем $q(\mathbf{Z})$:

$$\begin{aligned} \log q(\mathbf{Z}) &\approx \mathbb{E}_{q|\mathbf{Z}} \log p(\mathbf{y}, \mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{Z}, \boldsymbol{\pi}|\mathbf{X}, \mathbf{A}_1, \dots, \mathbf{A}_K, \boldsymbol{\mu}) \approx \\ &\approx \sum_{i=1}^N \sum_{k=1}^K z_{ik} (\mathbb{E} \log \pi_k + \mathbb{E} \log \sigma(y_i \mathbf{w}_k^\top \mathbf{x}_i)) \end{aligned} \quad (2.6)$$

Получили распределение $q(\mathbf{Z})$:

$$p(z_{ik} = 1) = \frac{\exp \mathbb{E} \log \pi_k + \mathbb{E} \log \sigma(y_i \mathbf{w}_l^\top \mathbf{x}_i)}{\sum_p (z_{ip} = 1)} \quad (2.7)$$

Найдем $q(\boldsymbol{\pi})$:

$$\begin{aligned} \log q(\boldsymbol{\pi}) &\approx \mathbb{E}_{q/\boldsymbol{\pi}} \log p(\mathbf{y}, \mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{Z}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}_1, \dots, \mathbf{A}_K, \boldsymbol{\mu}) \approx \\ &\approx \sum_{k=1}^K \log \pi_k \left(\mu_k - 1 + \sum_{i=1}^N \mathbb{E} z_{ik} \right) \end{aligned} \quad (2.8)$$

Получили распределение $q(\boldsymbol{\pi})$:

$$\log q(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu} + \boldsymbol{\gamma}), \quad \gamma_k = \sum_{i=1}^N z_{ik} \quad (2.9)$$

Найдем $q(\mathbf{W})$:

$$\begin{aligned} \log q(\mathbf{W}) &\approx \mathbb{E}_{q/\mathbf{W}} \log p(\mathbf{y}, \mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{Z}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}_1, \dots, \mathbf{A}_K, \boldsymbol{\mu}) \approx \\ &\approx \sum_{k=1}^K \left(-\frac{1}{2} \mathbf{w}_k \mathbf{A}_k \mathbf{w}_k + \sum_{i=1}^N \mathbb{E} z_{ik} \log \sigma(y_i \mathbf{w}_l^\top \mathbf{x}_i) \right) \end{aligned} \quad (2.10)$$

Сделаем М-шаг:

$$\begin{aligned} &\mathbb{E}_{q(\boldsymbol{\pi}, \mathbf{W}, \mathbf{Z})} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \boldsymbol{\mu}) = \mathcal{F}(\mathbf{A}) \propto \\ &\propto \sum_{k=1}^K \left[(\mu_k + 2\gamma_k - 1) \mathbb{E} \log \pi_k + \frac{1}{2} \log \det \mathbf{A}_k^{-1} - \frac{1}{2} \mathbb{E} \mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k \right] + \\ &\quad + \sum_{k=1}^K \left[\sum_{i=1}^N \mathbb{E} z_{ik} (\mathbb{E} \log \pi_k + \mathbb{E} \log \sigma(y_i \mathbf{w}_l^\top \mathbf{x}_i)) \right] \end{aligned} \quad (2.11)$$

Оптимизируем \mathbf{A}_k :

$$\frac{\partial \mathcal{F}}{\partial \mathbf{A}_k^{-1}} = \frac{1}{2} \mathbf{A}_k - \frac{1}{2} \mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top = \mathbf{0} \Rightarrow \mathbf{A}_k^{new} = \text{diag}(\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \quad (2.12)$$

Линейная регрессия. Рассматривается следующая вероятностная модель:

1. Веса моделей в смеси $\boldsymbol{\pi}$ получены из априорного распределения

$$p(\boldsymbol{\pi} | \boldsymbol{\mu});$$

2. Векторы параметров моделей \mathbf{w}_k получены из нормального распределения

$$p(\mathbf{w}_k | \mathbf{A}_k) = \mathcal{N}(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k), \quad k = 1, \dots, K;$$

3. Для каждого объекта \mathbf{x}_i выбрана модель \mathbf{f}_{k_i} , которой он описывается, причем $p(k_i = k) = \pi_k$;

4. Для каждого объекта \mathbf{x}_i класс y_i определен в соответствии с моделью

$$\mathbf{f}_{k_i} : y_i \sim \mathcal{N}(\mathbf{w}_{k_i}^\top \mathbf{x}_i + b_k, \beta^{-1})$$

Совместное правдоподобие модели:

$$p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}, \mathbf{b}, \beta, \mu) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu}) \prod_{k=1}^K N(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k) \prod_{i=1}^N \left(\sum_{k=1}^K \pi_k N(y_i | \mathbf{w}_k^\top \mathbf{x}_i + b_k, \beta^{-1}) \right) \quad (2.13)$$

Введем скрытые переменные $\mathbf{Z} = \{z_{ik}\}$, тогда совместное правдоподобие будет иметь вид:

$$p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \mathbf{b}, \beta, \mu) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu}) \prod_{k=1}^K N(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k) \prod_{i=1}^N \prod_{j=1}^K (\pi_k N(y_i | \mathbf{w}_k^\top \mathbf{x}_i + b_k, \beta^{-1}))^{z_{ik}} \quad (2.14)$$

Используем вариационное приближение (Е-шаг):

$$q(\boldsymbol{\pi}, \mathbf{W}, \mathbf{Z}) = q(\boldsymbol{\pi})q(\mathbf{W})q(\mathbf{Z}) \quad (2.15)$$

Найдем $q(\mathbf{Z})$:

$$\begin{aligned} \log q(\mathbf{Z}) &= \mathbb{E}_{q/Z} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \mathbf{b}, \beta, \mu) \propto \\ &\propto \sum_{i=1}^N \sum_{k=1}^K z_{ik} \left(\mathbb{E}_\pi \log \pi_k - \frac{\beta}{2} [y_i - b_k - \mathbf{w}_k^\top \mathbf{x}_i]^2 + \frac{1}{2} [\log \beta - \log 2\pi] \right) = \\ &= \sum_{i=1}^N \sum_{k=1}^K z_{ik} \left(\mathbb{E} \log \pi_k - \frac{\beta}{2} [(y_i - b_k)^2 - 2(y_i - b_k) \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i] \right) \Rightarrow \\ &\Rightarrow p(z_{ik} = 1) = \frac{\exp(\mathbb{E} \log \pi_k - \frac{\beta}{2} [(y_i - b_k)^2 - 2(y_i - b_k) \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i])}{\sum_k p(z_{ik} = 1)} \end{aligned} \quad (2.16)$$

Найдем $q(\boldsymbol{\pi})$:

$$\begin{aligned} \log q(\boldsymbol{\pi}) &= \mathbb{E}_{q/\pi} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \mathbf{b}, \beta, \mu) \propto \sum_{k=1}^K \log \pi_k \left(\mu_k - 1 + \sum_{i=1}^N \mathbb{E} z_{ik} \right) \Rightarrow \\ &\Rightarrow q(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu} + \boldsymbol{\gamma}), \quad \gamma_k = \sum_{i=1}^N \mathbb{E} z_{ik} \end{aligned} \quad (2.17)$$

Найдем $q(\mathbf{W})$:

$$\begin{aligned}
\log q(\mathbf{W}) &= \mathbb{E}_{q/\mathbf{W}} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z}|\mathbf{X}, \mathbf{A}, \mathbf{b}, \beta, \boldsymbol{\mu}) \propto \\
&\propto \sum_{k=1}^K -\frac{1}{2} \left(\mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k + \beta \sum_{i=1}^N \mathbb{E} z_{ik} [y_i - b_k - \mathbf{w}_k^\top \mathbf{x}_i]^2 \right) \propto \\
&\propto -\frac{1}{2} \sum_{k=1}^K \left(\mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k + \mathbf{w}_k^\top \left[\beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbb{E} z_{ik} \right] \mathbf{w}_k - 2\beta \mathbf{w}_k^\top \left[\sum_{i=1}^N \mathbf{x}_i (y_i - b_k) \mathbb{E} z_{ik} \right] \right) \propto \\
&\propto -\frac{1}{2} \sum_{k=1}^K (\mathbf{w}_k^\top \mathbf{B}_k^{-1} \mathbf{w}_k - 2\mathbf{w}_k^\top \mathbf{m}_k),
\end{aligned} \tag{2.18}$$

где введены обозначения

$$\mathbf{B}_k = \left(\mathbf{A}_k^{-1} + \beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbb{E} z_{ik} \right)^{-1} \quad \mathbf{m}_k = \beta \mathbf{B}_k \left(\sum_{i=1}^N \mathbf{x}_i (y_i - b_k) \mathbb{E} z_{ik} \right) \tag{2.19}$$

Получаем $q(\mathbf{W})$:

$$q(\mathbf{w}_k) = N(\mathbf{w}_k | \mathbf{m}_k, \mathbf{B}_k) \tag{2.20}$$

Сделаем М-шаг:

$$\begin{aligned}
\mathbb{E}_{q(\boldsymbol{\pi}, \mathbf{W}, \mathbf{Z})} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z}|\mathbf{X}, \mathbf{A}, \mathbf{b}, \beta, \boldsymbol{\mu}) &= \mathcal{F}(\mathbf{A}, \mathbf{b}, \beta) \propto \\
&\propto \sum_{k=1}^K \left[(\mu_k + 2\gamma_k - 1) \mathbb{E} \log \pi_k + \frac{1}{2} \log \det \mathbf{A}_k^{-1} - \frac{1}{2} \mathbb{E} \mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k \right] + \\
&+ \sum_{k=1}^K \left[\sum_{i=1}^N \mathbb{E} z_{ik} \left(\mathbb{E} \log \pi_k + \log \beta - \log 2\pi - \frac{\beta}{2} \mathbb{E} (y_i - b_k - \mathbf{w}_k^\top \mathbf{x}_i)^2 \right) \right]
\end{aligned} \tag{2.21}$$

Оптимизируем \mathbf{A}_k :

$$\frac{\partial \mathcal{F}}{\partial \mathbf{A}_k^{-1}} = \frac{1}{2} \mathbf{A}_k - \frac{1}{2} \mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top = \mathbf{0} \Rightarrow \mathbf{A}_k^{new} = \text{diag}(\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \tag{2.22}$$

Оптимизируем b_k :

$$\begin{aligned}
\frac{\partial \mathcal{F}}{\partial b_k} &= \sum_{i=1}^N \mathbb{E} z_{ik} (y_i - b_k - \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k) = 0 \Rightarrow \\
\Rightarrow b_k^{new} &= \frac{1}{S_k} \sum_{i=1}^N y_i \mathbb{E} z_{ik} - \frac{1}{S_k} \sum_{i=1}^N \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k \mathbb{E} z_{ik}, \quad S_k = \sum_{i=1}^N \mathbb{E} z_{ik}
\end{aligned} \tag{2.23}$$

Оптимизируем β :

$$\begin{aligned} \frac{\partial \mathcal{F}}{\partial \beta} &= \sum_{k=1}^K \sum_{i=1}^N \left(\frac{1}{\beta} \mathbb{E} z_{ik} - \frac{1}{2} \mathbb{E} z_{ik} [(y_i - b_k)^2 - 2(y_i - b_k) \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i] \right) = 0 \Rightarrow \\ &\Rightarrow \frac{1}{\beta^{new}} = \frac{\sum \sum [(y_i - b_k)^2 - 2(y_i - b_k) \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i] \mathbb{E} z_{ik}}{\sum \sum \mathbb{E} z_{ik}} \end{aligned} \quad (2.24)$$

Оптимизируем μ_k (пока нет):

$$\frac{\partial \mathcal{F}}{\partial \mu_k} = ??? \quad (2.25)$$

Важные матожидания:

$$\begin{aligned} \mathbb{E} z_{ik} &= p(z_{ik} = 1) \\ \mathbb{E} \log \pi_k &= \psi^0(\mu_k + \gamma_k) - \psi^0(K\mu_k + N) \\ \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top &= \mathbf{B}_k + \mathbf{m}_k \mathbf{m}_k^\top \end{aligned} \quad (2.26)$$

2.2 Смесь экспертов

Определение 2.2. Смесь экспертов — мультимодель, определяющая правдоподобие каждой π_k каждой модели \mathbf{f}_k на объекте \mathbf{x} на основе его признакового описания.

$$\hat{\mathbf{f}} = \sum_{k=1}^K \pi_k \mathbf{f}_k, \quad \pi_k(\mathbf{x}, \mathbf{v}) : \mathbb{R}^{2 \times n} \rightarrow [0, 1], \quad (2.27)$$

где \mathbf{f} — мультимодель, а \mathbf{f}_k является некоторой моделью.

Линейная регрессия. Рассматривается следующая вероятностная модель:

1. one

2. two

Совместное правдоподобие модели:

$$\begin{aligned} p(\mathbf{y}, \mathbf{W}, \mathbf{V}, \mathbf{Z}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}, \mathbf{C}, \beta) &= \\ &= \prod_{k=1}^K \mathcal{N}(\mathbf{v}_k | \mathbf{0}, \mathbf{C}_k) \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k) \prod_{i=1}^N \left[\left(\sum_{k=1}^K \pi_{ik} \mathcal{N}(y_i | \mathbf{w}_k^\top \mathbf{x}_i, \beta^{-1}) \right) \text{Dir}(\boldsymbol{\pi}_i | \boldsymbol{\mu}_i) \right], \end{aligned} \quad (2.28)$$

где $\boldsymbol{\mu}_i = \exp(\mathbf{V} \mathbf{x}_i)$

Введем скрытые переменные $\mathbf{Z} = ||z_{ik}||$, тогда совместное правдоподобие будет иметь вид:

$$p(\mathbf{y}, \mathbf{W}, \mathbf{V}, \mathbf{Z}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}, \mathbf{C}, \beta) = \prod_{k=1}^K \mathcal{N}(\mathbf{v}_k | \mathbf{0}, \mathbf{C}_k) \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k) \prod_{i=1}^N \left[\left(\prod_{k=1}^K (\pi_{ik} \mathcal{N}(y_i | \mathbf{w}_k^\top \mathbf{x}_i, \beta^{-1}))^{z_{ik}} \right) \text{Dir}(\boldsymbol{\pi}_i | \boldsymbol{\mu}_i) \right], \quad (2.29)$$

где $\boldsymbol{\mu}_i = \exp(\mathbf{V} \mathbf{x}_i)$

Используем вариационное приближение (Е-шаг):

$$q(\mathbf{V}, \mathbf{W}, \mathbf{Z}, \boldsymbol{\pi}) = q(\mathbf{V}) q(\mathbf{W}) q(\mathbf{Z}) q(\boldsymbol{\pi}) \quad (2.30)$$

Найдем $q(\mathbf{Z})$:

$$\begin{aligned} \log q(\mathbf{Z}) &= \mathbb{E}_{q/\mathbf{Z}} p(\mathbf{y}, \mathbf{W}, \mathbf{V}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \mathbf{C}, \beta) \propto \\ &\propto \sum_{i=1}^N \sum_{k=1}^K z_{ik} \left(\mathbb{E} \log \pi_{ik} - \frac{\beta}{2} [y_i - \mathbf{w}_k^\top \mathbf{x}_i]^2 \right) = \\ &= \sum_{i=1}^N \sum_{k=1}^K z_{ik} \left(\mathbb{E} \log \pi_{ik} - \frac{\beta}{2} [y_i^2 - 2y_i \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i] \right) \Rightarrow \\ &\Rightarrow p(z_{ik} = 1) = \frac{\mathbb{E} \log \pi_{ik} - \frac{\beta}{2} [y_i^2 - 2y_i \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i]}{\sum_k p(z_{ik} = 1)} \end{aligned} \quad (2.31)$$

Найдем $q(\mathbf{W})$:

$$\begin{aligned} \log q(\mathbf{W}) &= \mathbb{E}_{q/\mathbf{W}} p(\mathbf{y}, \mathbf{W}, \mathbf{V}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \mathbf{C}, \beta) \propto \\ &\propto \sum_{k=1}^K -\frac{1}{2} \left(\mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k + \beta \sum_{i=1}^N \mathbb{E} z_{ik} [y_i - \mathbf{w}_k^\top \mathbf{x}_i]^2 \right) \propto \\ &\propto -\frac{1}{2} \sum_{k=1}^K \left(\mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k + \mathbf{w}_k^\top \left[\beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbb{E} z_{ik} \right] \mathbf{w}_k - 2\beta \mathbf{w}_k^\top \left[\sum_{i=1}^N \mathbf{x}_i y_i \mathbb{E} z_{ik} \right] \right) \propto \\ &\propto -\frac{1}{2} \sum_{k=1}^K (\mathbf{w}_k^\top \mathbf{B}_k^{-1} \mathbf{w}_k - 2\mathbf{w}_k^\top \mathbf{m}_k), \end{aligned} \quad (2.32)$$

где введены обозначения

$$\mathbf{B}_k = \left(\mathbf{A}_k^{-1} + \beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbb{E} z_{ik} \right)^{-1} \quad \mathbf{m}_k = \beta \mathbf{B}_k \left(\sum_{i=1}^N \mathbf{x}_i y_i \mathbb{E} z_{ik} \right) \quad (2.33)$$

Получаем $q(\mathbf{W})$:

$$q(\mathbf{w}_k) = N(\mathbf{w}_k | \mathbf{m}_k, \mathbf{B}_k) \quad (2.34)$$

Найдем $q(\boldsymbol{\pi})$:

$$\begin{aligned} \log q(\boldsymbol{\pi}) &= \mathbb{E}_{q/\pi} p(\mathbf{y}, \mathbf{W}, \mathbf{V}, \mathbf{Z}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}, \mathbf{C}, \beta) \propto \\ &\propto \sum_{i=1}^N \sum_{k=1}^K \log \pi_{ik} (\exp(\mathbf{v}_k^\top \mathbf{x}_i) - 1 + \mathbb{E} z_{ik}) \Rightarrow \boldsymbol{\pi}_i \sim \text{Dir}(\boldsymbol{\pi}_i | \boldsymbol{\mu}_i + \boldsymbol{\gamma}_i), \quad \gamma_{ik} = \mathbb{E} z_{ik} \end{aligned} \quad (2.35)$$

Найдем $q(\mathbf{V})$:

$$\begin{aligned} \log q(\mathbf{V}) &= \mathbb{E}_{q/\mathbf{V}} p(\mathbf{y}, \mathbf{W}, \mathbf{V}, \mathbf{Z}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}, \mathbf{C}, \beta) \propto \\ &\propto \sum_{k=1}^K -\frac{1}{2} \left(\mathbf{v}_k^\top \mathbf{C}_k^{-1} \mathbf{v}_k + \sum_{i=1}^N \mathbb{E} \log \pi_{ik} [\exp(\mathbf{v}_k^\top \mathbf{x}_i) - 1] \right) \end{aligned} \quad (2.36)$$

Сделаем М-шаг

Линейная регрессия без prior. Рассматривается следующая вероятностная модель:

1. one
2. two

3 Постановка задачи смеси экспертов

Задана выборка:

$$\mathbf{X} \in \mathbb{R}^{N \times n}, \quad (3.1)$$

где N — количество объектов в выборке, а n — размерность признакового пространства.

Определение 3.1. Смесь экспертов — мультимодель, определяющая правдоподобие каждой π_k каждой модели \mathbf{f}_k на объекте \mathbf{x} на основе его признакового описания.

$$\hat{\mathbf{f}} = \sum_{k=1}^K \pi_k \mathbf{f}_k, \quad \pi_k(\mathbf{x}, \mathbf{V}) : \mathbb{R}^{2 \times n} \rightarrow [0, 1], \quad \sum_{k=1}^K \pi_k(\mathbf{x}, \mathbf{V}) = 1 \quad (3.2)$$

где \mathbf{f} — мультимодель, а \mathbf{f}_k является некоторой моделью, π_k — параметрическая модель.

3.1 Общий случай

Правдоподобие модели:

$$p(\mathbf{y}, \mathbf{W}, \mathbf{Z} | \mathbf{X}, \mathbf{V}, \mathbf{A}) = \prod_{i=1}^N \prod_{k=1}^K [\pi_k(\mathbf{x}_i, \mathbf{V}) p_k(y_i | \mathbf{w}_k, \mathbf{x}_i)]^{z_{ik}} \prod_{k=1}^K p^k(\mathbf{w}_k | \mathbf{A}_k) \quad (3.3)$$

Логарифм правдоподобия модели:

$$\begin{aligned} \log p(\mathbf{y}, \mathbf{W}, \mathbf{Z}|\mathbf{X}, \mathbf{V}, \mathbf{A}) &= \sum_{i=1}^N \sum_{k=1}^K z_{ik} [\log \pi_k(\mathbf{x}_i, \mathbf{V}) + \log p_k(y_i|\mathbf{w}_k, \mathbf{x}_i)] + \\ &+ \sum_{k=1}^K \log p^k(\mathbf{w}_k|\mathbf{A}_k) \end{aligned} \quad (3.4)$$

E-step

Найдем $q(\mathbf{Z})$:

$$\begin{aligned} \log q(\mathbf{Z}) &= \mathbb{E}_{q/\mathbf{Z}} \log p(\mathbf{y}, \mathbf{W}, \mathbf{Z}|\mathbf{X}, \mathbf{V}, \mathbf{A}) \\ p(z_{ik} = 1) &= \frac{\exp(\log \pi_k(\mathbf{x}_i, \mathbf{V}) + \mathbb{E} \log p_k(y_i|\mathbf{w}_k, \mathbf{A}_k))}{\sum_{k'=1}^K \exp(\log \pi_{k'}(\mathbf{x}_i, \mathbf{V}) + \mathbb{E} \log p_{k'}(y_i|\mathbf{w}'_k, \mathbf{A}'_k))} \end{aligned} \quad (3.5)$$

Найдем $q(\mathbf{W})$:

$$\begin{aligned} \log q(\mathbf{W}) &= \mathbb{E}_{q/\mathbf{W}} \log p(\mathbf{y}, \mathbf{W}, \mathbf{Z}|\mathbf{X}, \mathbf{V}, \mathbf{A}) \\ &= \sum_{i=1}^N \sum_{k=1}^K \mathbb{E} z_{ik} [\log \pi_k(\mathbf{x}_i, \mathbf{V}) + \log p_k(y_i|\mathbf{w}_k, \mathbf{x}_i)] + \\ &+ \sum_{k=1}^K \log p^k(\mathbf{w}_k, \mathbf{A}_k) \end{aligned} \quad (3.6)$$

M-step

$$\begin{aligned} \mathbb{E}_q p(\mathbf{y}, \mathbf{W}, \mathbf{Z}|\mathbf{X}, \mathbf{V}, \mathbf{A}) &= \mathcal{F}(\mathbf{V}, \mathbf{A}) \\ \mathcal{F}(\mathbf{V}, \mathbf{A}) &= \sum_{i=1}^N \sum_{k=1}^K \mathbb{E} z_{ik} [\log \pi_k(\mathbf{x}_i, \mathbf{V}) + \mathbb{E} \log p_k(y_i|\mathbf{w}_k, \mathbf{x}_i)] \\ &+ \sum_{k=1}^K \mathbb{E} \log p_k(\mathbf{w}_k|\mathbf{A}_k) \end{aligned} \quad (3.7)$$

Найдем \mathbf{A} из условия:

$$\frac{\partial \mathcal{F}(\mathbf{V}, \mathbf{A})}{\partial \mathbf{A}^{-1}} = 0 \quad (3.8)$$

Найдем \mathbf{V} :

Аналитически решение не ищется, поэтому воспользуемся градиентным спуском для максимизации правдоподобия модели:

$$\mathbf{V}^{j+1} = \mathbf{V}^j + \alpha \frac{\partial \mathcal{F}(\mathbf{W}, \mathbf{V}^j, \beta)}{\partial \mathbf{V}} \quad (3.9)$$

3.2 Случай $p_k(y_i|\mathbf{X}, \mathbf{w}_k) = \mathbf{N}(y_i|\mathbf{w}_k^\top \mathbf{x}_i, \beta^{-1})$

E-step

Для нахождения $q(\mathbf{Z})$ требуется:

$$\mathbb{E} \log p_k(y_i|\mathbf{w}_k, \mathbf{A}_k) = -\frac{\beta}{2} (y_i^2 - 2y_i \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i) + \frac{1}{2} (\log \beta - \log 2\pi) \quad (3.10)$$

Найдем $q(\mathbf{w}_k)$:

$$\begin{aligned} \log q(\mathbf{w}_k) &\propto -\frac{1}{2} \left(\mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k + \beta \sum_{i=1}^N \mathbb{E} z_{ik} [y_i - \mathbf{w}_k^\top \mathbf{x}_i]^2 \right) \propto \\ &\propto -\frac{1}{2} (\mathbf{w}_k - \mathbf{m}_k)^\top \mathbf{B}_k^{-1} (\mathbf{w}_k - \mathbf{m}_k) \end{aligned} \quad (3.11)$$

где введены обозначения:

$$\mathbf{B}_k = \left(\mathbf{A}_k^{-1} + \beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbb{E} z_{ik} \right)^{-1}, \quad \mathbf{m}_k = \beta \mathbf{B}_k \left(\sum_{i=1}^N \mathbf{x}_i y_i \mathbb{E} z_{ik} \right). \quad (3.12)$$

M-step

$$\mathbb{E}_q p(\mathbf{y}, \mathbf{W}, \mathbf{Z}|\mathbf{X}, \mathbf{V}, \mathbf{A}, \beta) = \mathcal{F}(\mathbf{V}, \mathbf{A}, \beta).$$

$$\begin{aligned} \mathbb{E} \log p_k(y_i|\mathbf{w}_k, \mathbf{x}_i) &= -\frac{\beta}{2} (y_i^2 - 2y_i \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i) + \frac{1}{2} (\log \beta - \log 2\pi) \\ \mathbb{E} \log p_k(\mathbf{w}_k|\mathbf{A}_k) &= -\frac{1}{2} \mathbb{E} \mathbf{w}_k^\top \mathbf{A}_k^{-1} \mathbf{w}_k + \frac{1}{2} \log \det \mathbf{A}_k^{-1} - \frac{n}{2} \log 2\pi \end{aligned} \quad (3.13)$$

Найдем β :

$$\begin{aligned} \frac{\partial \mathcal{F}(\mathbf{V}, \mathbf{A}, \beta)}{\partial \beta} &= \sum_{k=1}^K \sum_{i=1}^N \left(\frac{1}{\beta} \mathbb{E} z_{ik} - \frac{1}{2} \mathbb{E} z_{ik} [y_i^2 - 2y_i \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i] \right) = 0 \\ \frac{1}{\beta} &= \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K [y_i^2 - 2y_i \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i] \mathbb{E} z_{ik} \end{aligned} \quad (3.14)$$

Найдем \mathbf{A} :

$$\frac{\partial \mathcal{F}(\mathbf{V}, \mathbf{A}, \beta)}{\partial \mathbf{A}^{-1}} = \frac{1}{2} \mathbf{A}_k - \frac{1}{2} \mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top = 0 \Rightarrow \mathbf{A}_k^{\text{new}} = \text{diag}(\mathbb{E} \mathbf{w}_k \mathbf{w}_k^\top) \quad (3.15)$$

Найдем \mathbf{V} :

Аналитически решение не ищется, поэтому воспользуемся градиентным спуском для максимизации правдоподобия модели:

$$\mathbf{V}^{j+1} = \mathbf{V}^j + \alpha \frac{\partial \mathcal{F}(\mathbf{W}, \mathbf{V}^j, \beta)}{\partial \mathbf{V}} \quad (3.16)$$

3.3 Случай $p_k(y_i|\mathbf{X}, \mathbf{w}_k) = \text{Exp}\left(y_i - \mathbf{w}_k^E \mathbf{x}_i \middle| \frac{\beta}{2}\right)$

E-step

Для нахождения $q(\mathbf{Z})$ требуется:

$$\mathbb{E} \log p_k(y_i|\mathbf{w}_k, \mathbf{A}_k) = \log \frac{\beta}{2} - \frac{\beta}{2} (y_i - \mathbf{w}_k^T \mathbf{x}_i) \quad (3.17)$$

Найдем $q(\mathbf{w}_k)$:

$$\begin{aligned} \log q(\mathbf{w}_k) &\propto -\frac{1}{2} \left(\mathbf{w}_k^T \mathbf{A}_k^{-1} \mathbf{w}_k + \frac{\beta}{2} \sum_{i=1}^N \mathbb{E} z_{ik} [y_i - \mathbf{w}_k^T \mathbf{x}_i] \right) \propto \\ &\propto -\frac{1}{2} (\mathbf{w}_k - \mathbf{m}_k)^T \mathbf{A}_k^{-1} (\mathbf{w}_k - \mathbf{m}_k) \end{aligned} \quad (3.18)$$

где введено обозначения:

$$\mathbf{m}_k = \frac{\beta}{2} \mathbf{A}_k \left(\sum_{i=1}^N \mathbf{x}_i \mathbb{E} z_{ik} \right). \quad (3.19)$$

M-step

$$\mathbb{E}_q p(\mathbf{y}, \mathbf{W}, \mathbf{Z}|\mathbf{X}, \mathbf{V}, \mathbf{A}, \beta) = \mathcal{F}(\mathbf{V}, \mathbf{A}, \beta).$$

$$\mathbb{E} \log p_k(y_i|\mathbf{w}_k, \mathbf{x}_i) = \log \frac{\beta}{2} - \frac{\beta}{2} (y_i - \mathbf{w}_k^T \mathbf{x}_i) \quad (3.20)$$

$$\mathbb{E} \log p_k(\mathbf{w}_k|\mathbf{A}_k) = -\frac{1}{2} \mathbb{E} \mathbf{w}_k^T \mathbf{A}_k^{-1} \mathbf{w}_k + \frac{1}{2} \log \det \mathbf{A}_k^{-1} - \frac{n}{2} \log 2\pi$$

Найдем β :

$$\begin{aligned} \frac{\partial \mathcal{F}(\mathbf{V}, \mathbf{A}, \beta)}{\partial \beta} &= \sum_{k=1}^K \sum_{i=1}^N \mathbb{E} z_{ik} \left[\frac{1}{\beta} - \frac{y_i - \mathbf{w}_k^T \mathbf{x}_i}{2} \right] = 0 \\ \frac{1}{\beta} &= \frac{1}{2N} \sum_{i=1}^N \sum_{k=1}^K (y_i - \mathbf{w}_k^T \mathbf{x}_i) \mathbb{E} z_{ik} \end{aligned} \quad (3.21)$$

Найдем \mathbf{A} :

$$\frac{\partial \mathcal{F}(\mathbf{V}, \mathbf{A}, \beta)}{\partial \mathbf{A}^{-1}} = \frac{1}{2} \mathbf{A}_k - \frac{1}{2} \mathbb{E} \mathbf{w}_k \mathbf{w}_k^T = 0 \Rightarrow \mathbf{A}_k^{new} = \text{diag}(\mathbb{E} \mathbf{w}_k \mathbf{w}_k^T) \quad (3.22)$$

Найдем \mathbf{V} :

Аналитически решение не ищется, поэтому воспользуемся градиентным спуском для максимизации правдоподобия модели:

$$\mathbf{V}^{j+1} = \mathbf{V}^j + \alpha \frac{\partial \mathcal{F}(\mathbf{W}, \mathbf{V}^j, \beta)}{\partial \mathbf{V}} \quad (3.23)$$

4 Вычислительный эксперимент

5 Заключение

Список литературы